

Proyecto Integrado (EA2). Análisis de una necesidad de ingeniería de datos

Integrante:

Juan Diego Urrego Gutiérrez

Proyecto Integrado V - Línea de Énfasis - PREICA2502B020074

Docente: Andrés Felipe Callejas Jaramillo

Institución Universitaria Digital de Antioquia

Medellín - Colombia

23 de noviembre del 2025

Contenido

Introducción	3
Resumen (Abstract).....	4
Descripción	5
Objetivo general	5
Objetivos específicos	5
Variables relevantes	6
Metodología	6
Preparación e Ingesta de Datos	6
Diseño de la Arquitectura del Pipeline	6
Limpieza de Datos	6
Enriquecimiento del Dataset.....	7
Análisis Descriptivo y Exploratorio (EDA)	7
Desarrollo y Análisis de Datos.....	7
Repository	13
https://github.com/JuanUrrego/EA_proyecto_integrado_V_20251-2	13
Conclusiones	14
Referencias	15

Introducción

El presente proyecto desarrolla la formulación y el análisis de una necesidad de ingeniería de datos enfocada en comprender cómo los estilos de vida influyen en los riesgos de salud dentro de una población adulta. Esta iniciativa se enmarca en el contexto de la ciudad de Medellín, donde las instituciones de salud enfrentan el reto de anticiparse a la aparición de enfermedades crónicas no transmisibles como la hipertensión y la diabetes, patologías fuertemente relacionadas con hábitos de alimentación, actividad física y descanso.

Para este propósito se seleccionó un conjunto de datos público disponible en la plataforma Kaggle, el cual contiene información sobre variables asociadas a estilos de vida, tales como actividad física, horas de sueño, ingesta de azúcar, IMC y edad. A este dataset se le realizaron procesos de enriquecimiento temporal, generando fechas comprendidas entre los años 2022 y 2024, con el fin de habilitar análisis comparativos y gráficos de tendencias.

Para analizar los datos se procedió a depurar, enriquecer y analizar el dataset mediante técnicas de limpieza, normalización y visualización, con el objetivo de transformar los datos en información valiosa que facilite la identificación de patrones y potenciales factores de riesgo para la salud. Los resultados obtenidos nos confirman que la estructura del dataset y las relaciones identificadas permiten avanzar hacia técnicas predictivas que puedan estimar probabilidad de desarrollar condiciones relacionadas con estilo de vida (obesidad, riesgo metabólico, mala calidad del sueño, inactividad física).

Resumen (Abstract)

Este documento presenta el análisis de un conjunto de datos sobre estilos de vida y riesgos de salud, con el objetivo de generar información útil que apoye a una IPS pública de Medellín en la toma de decisiones preventivas. A partir de un dataset de Kaggle, se desarrolló un proceso integral de limpieza, normalización, enriquecimiento temporal y análisis descriptivo, centrado en cinco variables clave: edad, IMC, actividad física, horas de sueño e ingesta de azúcar.

Para este proyecto, se eliminaron duplicados y valores inconsistentes, se estandarizaron los tipos de datos, se generaron nuevas columnas temporales (año, mes, día) y se construyeron variables categóricas que permiten una interpretación más clara del comportamiento poblacional. Posteriormente, se aplicaron técnicas de análisis exploratorio (EDA), incluyendo estadísticas descriptivas, histogramas, gráficos de barras, mapas de correlación y tendencias temporales.

Los resultados obtenidos evidencian patrones relacionados con sobrepeso, niveles bajos de ejercicio, hábitos de sueño moderados y consumo de azúcar medio-bajo, lo cual es relevante para evaluar riesgos metabólicos y de enfermedades crónicas. Este análisis sienta las bases para estudios posteriores enfocados en modelamiento predictivo y generación de indicadores que contribuyan a fortalecer la salud pública en la ciudad haciendo uso de la visualización mediante un dashboard que resumirá gráficamente el comportamiento de las cinco variables clave.

Palabras clave: estilos de vida, riesgo de salud, IMC, ejercicio, sueño, Kaggle, ingeniería de datos, Medellín, EDA.

Descripción

En Medellín, las entidades prestadoras de salud requieren herramientas que permitan analizar de forma anticipada los factores asociados al desarrollo de enfermedades crónicas. Este proyecto busca aportar a ese propósito mediante la preparación, depuración, análisis y visualización de un dataset de estilos de vida, con el fin de identificar patrones relevantes que contribuyan al entendimiento de los riesgos de salud en población adulta.

El proyecto integra elementos de ingeniería de datos y análisis exploratorio para organizar la información, mejorar su calidad y generar visualizaciones interpretativas que permitan comprender la dinámica de variables clave como el IMC, la actividad física, el sueño y la alimentación.

Objetivo general

Implementar un proceso de transformación y análisis descriptivo de datos basado en un dataset público de estilos de vida, con el fin de comprender patrones asociados a riesgos de salud en población adulta de Medellín.

Objetivos específicos

- Preparar y depurar los datos descargados desde Kaggle, registrando su origen, estandarizando nombres y tipos de datos y corrigiendo duplicados o inconsistencias para asegurar su calidad.
- Enriquecer la información mediante la creación de variables temporales (año, mes, día) y categorías analíticas como grupos de edad, niveles de IMC, actividad física, sueño e ingesta de azúcar.
- Realizar un análisis exploratorio que incluya estadísticas descriptivas y visualizaciones para identificar patrones, distribuciones y relaciones entre las variables clave.
- Documentar todo el proceso en el repositorio GitHub, garantizando trazabilidad de los cambios y estructurando el informe académico según Normas APA.

Variables relevantes

- age: Edad del individuo (factor de riesgo base).
- bmi: Índice de masa corporal, proxy nutricional.
- sleep: Horas de sueño por día.
- sugar_intake: Ingesta estimada de azúcar.
- exercise: Nivel de ejercicio

Metodología

El proyecto se desarrolla bajo un enfoque ágil, empleando la metodología Scrum. La metodología aplicada incluye:

Preparación e Ingesta de Datos

Se realizó la descarga del dataset desde la plataforma Kaggle, asegurando el registro adecuado de la licencia, la fuente original y la ruta de acceso utilizada. El conjunto de datos fue trasladado a un entorno virtual alojado en GitHub para facilitar la reproducibilidad y el control del proyecto. Posteriormente, los datos fueron cargados en una base de datos SQLite como mecanismo centralizado de almacenamiento, y se generó un archivo CSV de verificación con el fin de validar la correcta ingestión y estructuración del contenido.

Diseño de la Arquitectura del Pipeline

Se definió una arquitectura mínima de procesamiento basada en el flujo Dataset → SQLite → CSV, lo que permite asegurar un manejo ordenado y replicable de los datos. Este diseño se integró con un sistema de control de versiones en GitHub, garantizando la trazabilidad completa de los cambios realizados, así como la documentación de cada una de las etapas del proceso, desde la ingestión hasta la generación de artefactos finales.

Limpieza de Datos

Se desarrolló un proceso de depuración orientado a garantizar la calidad y consistencia del dataset antes del análisis. Este incluyó la identificación y eliminación de duplicados, la corrección de valores nulos e inconsistencias, y la normalización de tipos de datos mediante reglas estandarizadas. Asimismo, se homogenizó la estructura del dataset aplicando una nomenclatura uniforme a las columnas. Todas las transformaciones

realizadas fueron documentadas dentro del notebook para asegurar trazabilidad metodológica.

Enriquecimiento del Dataset

Una vez limpio el dataset, se generaron nuevas variables para ampliar su valor analítico. Dado que el conjunto de datos original no incluía fechas, se creó una columna temporal con valores aleatorios en el rango 2022–2024, a partir de la cual se derivaron las variables de año, mes y día. De forma complementaria, se construyeron variables categóricas comparativas —como rangos de edad, categorías de IMC, niveles de sueño, actividad física e ingesta de azúcar— que facilitaron la interpretación de patrones. El dataset enriquecido fue exportado en formato CSV y se dejó constancia del proceso en el notebook.

Análisis Descriptivo y Exploratorio (EDA)

Con la base de datos lista, se aplicaron técnicas de análisis descriptivo para comprender la distribución, comportamiento y relaciones entre las variables seleccionadas. Se generaron estadísticas básicas (media, desviación estándar, mínimos, máximos y cuartiles) y se visualizaron las distribuciones mediante histogramas y gráficos de barras. Se elaboró una matriz de correlación para identificar relaciones lineales y un análisis temporal apoyado en la columna de fecha simulada. Cada visualización fue acompañada de una interpretación breve que permitió contextualizar los hallazgos.

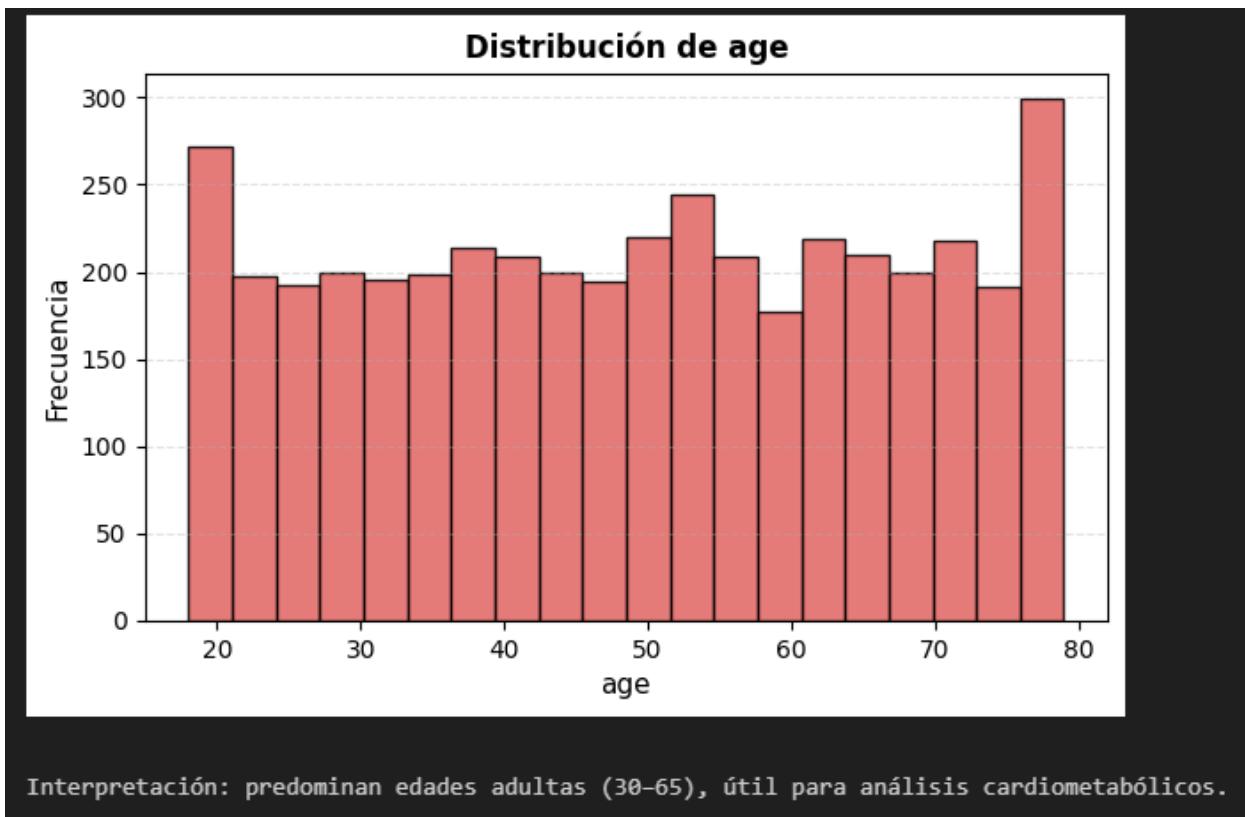
Desarrollo y Análisis de Datos

El análisis descriptivo y exploratorio realizado sobre el dataset enriquecido brindó una comprensión clara del comportamiento de las cinco variables clave del estudio: edad, índice de masa corporal, ejercicio, sueño e ingesta de azúcar. A partir de 4.257 registros, se identificó que la población es mayoritariamente adulta, con una edad media cercana a los 49 años y un BMI promedio de 26.8, indicador de sobrepeso. Las tendencias muestran niveles bajos y moderados de actividad física, patrones de sueño relativamente estables alrededor de 7 horas y una ingesta de azúcar mayoritariamente baja o media.

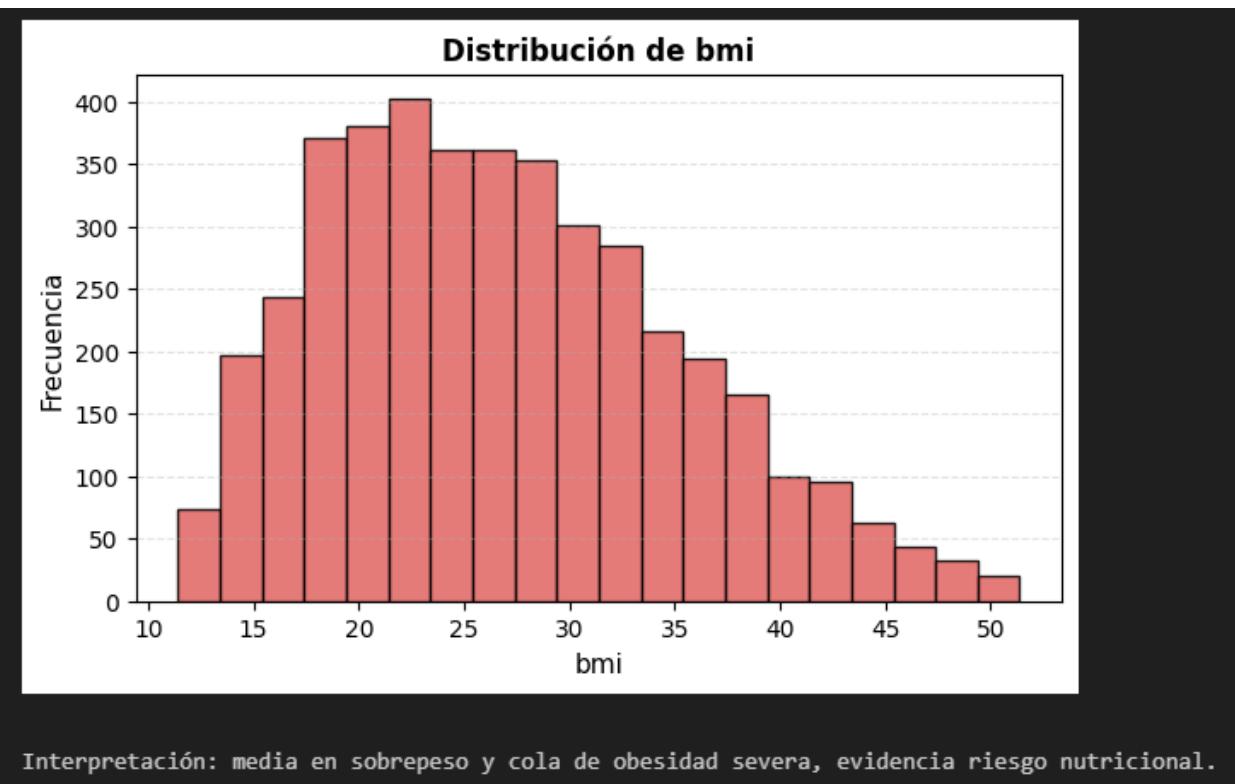
Las visualizaciones —como histogramas, gráficos de barras y una matriz de correlación— permitieron evidenciar concentraciones específicas, asimetrías en la distribución de BMI y ejercicio, así como correlaciones lineales débiles entre las variables, lo que refleja una independencia relativa entre los hábitos analizados. Además, el análisis temporal con fechas generadas mostró una estabilidad general en los promedios mensuales sin estacionalidades relevantes.

En conjunto, estos hallazgos aportan una visión integral del estado y hábitos de la población estudiada, destacan posibles riesgos asociados y confirman la calidad del

dataset para avanzar hacia etapas posteriores de análisis e interpretación en el marco del proyecto.

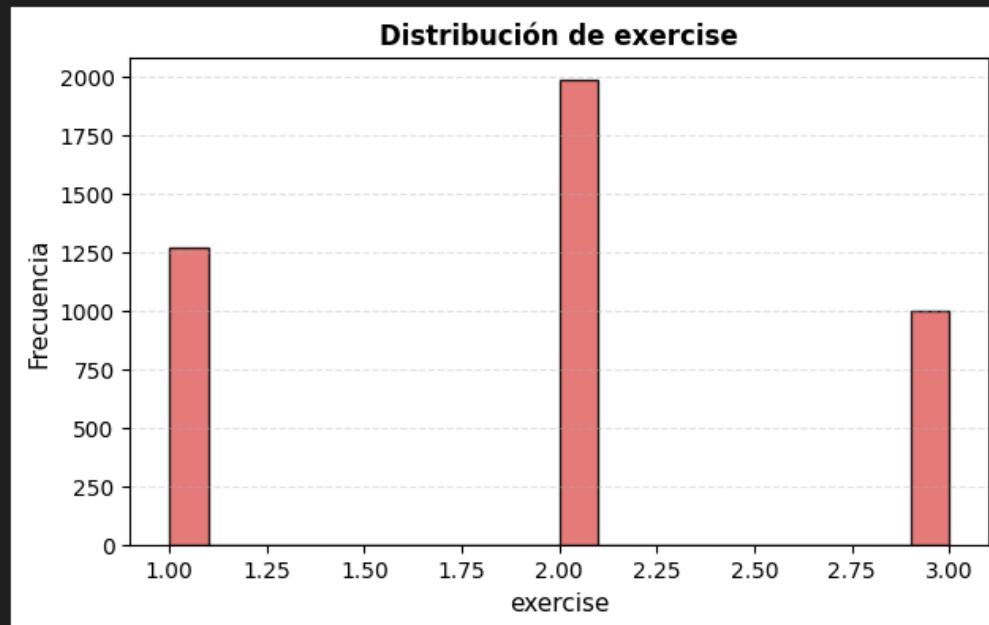


La distribución de **age** muestra una población predominantemente adulta, con concentración entre los 30 y 65 años. Hay pocos valores en los extremos (jóvenes <25 y mayores >70), lo que indica que el dataset se enfoca en población adulta, ideal para estudios de salud y estilo de vida.



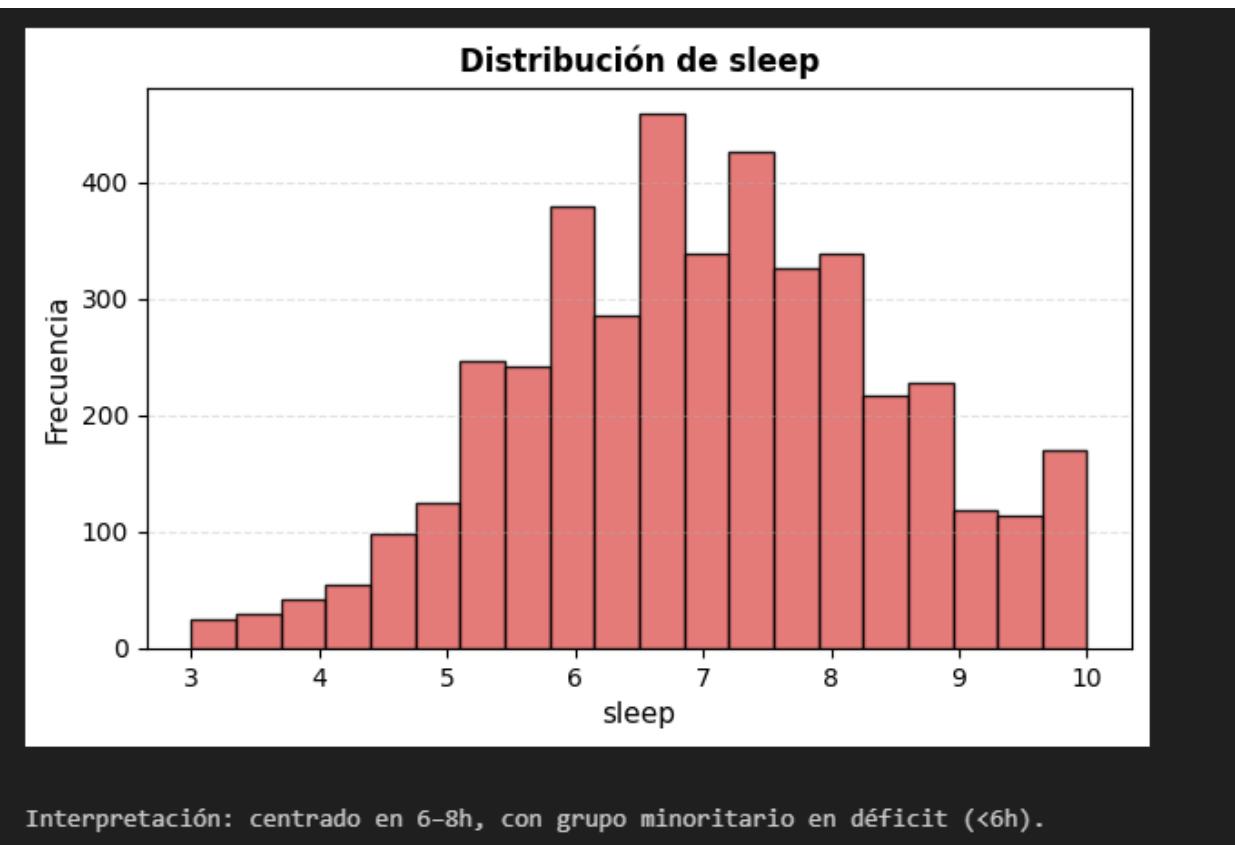
El IMC o BMI se distribuye de forma amplia, con un promedio alrededor de 26–27, lo cual corresponde a **sobrepeso** según clasificación OMS. Se observan valores extremos que representan casos de obesidad severa ($IMC > 40$), lo que aporta variabilidad útil para análisis de riesgo.

Interpretación: media en sobrepeso y cola de obesidad severa, evidencia riesgo nutricional.



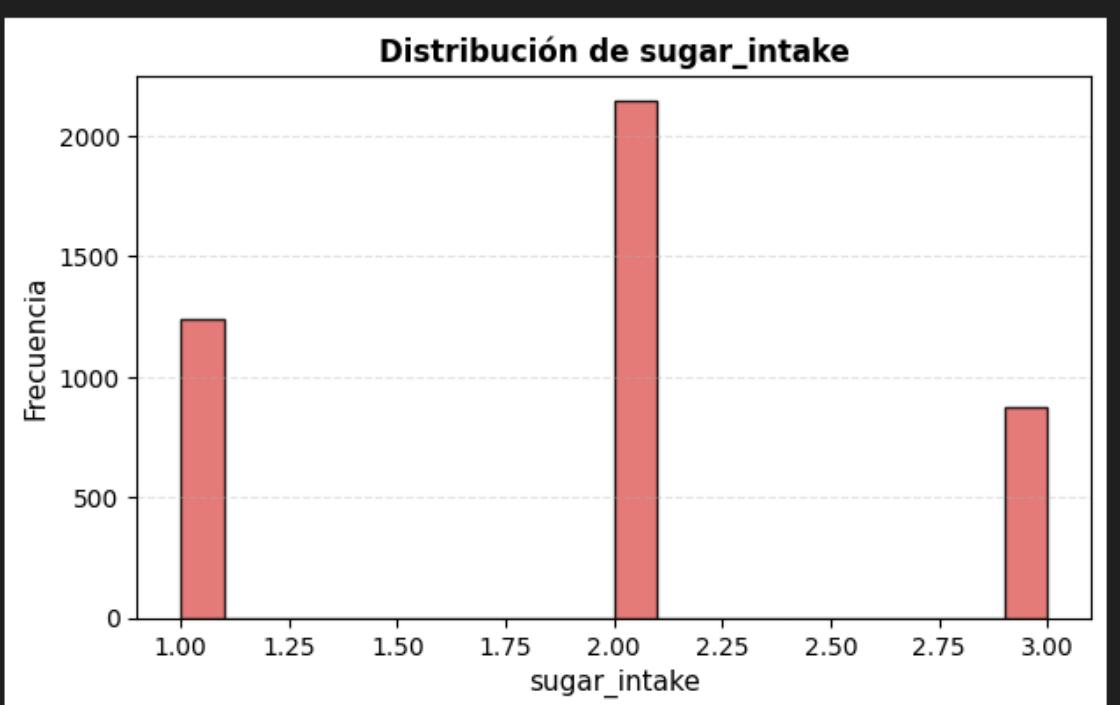
Interpretación: concentración en niveles bajos/medios, sugiere tendencia al sedentarismo.

La mayor concentración está en niveles 1 y 2 (actividad baja y moderada). Los niveles altos (3) son minoritarios. Esto sugiere que la población tiene una **tendencia al sedentarismo**, lo cual puede relacionarse con IMC elevados o hábitos no saludables.



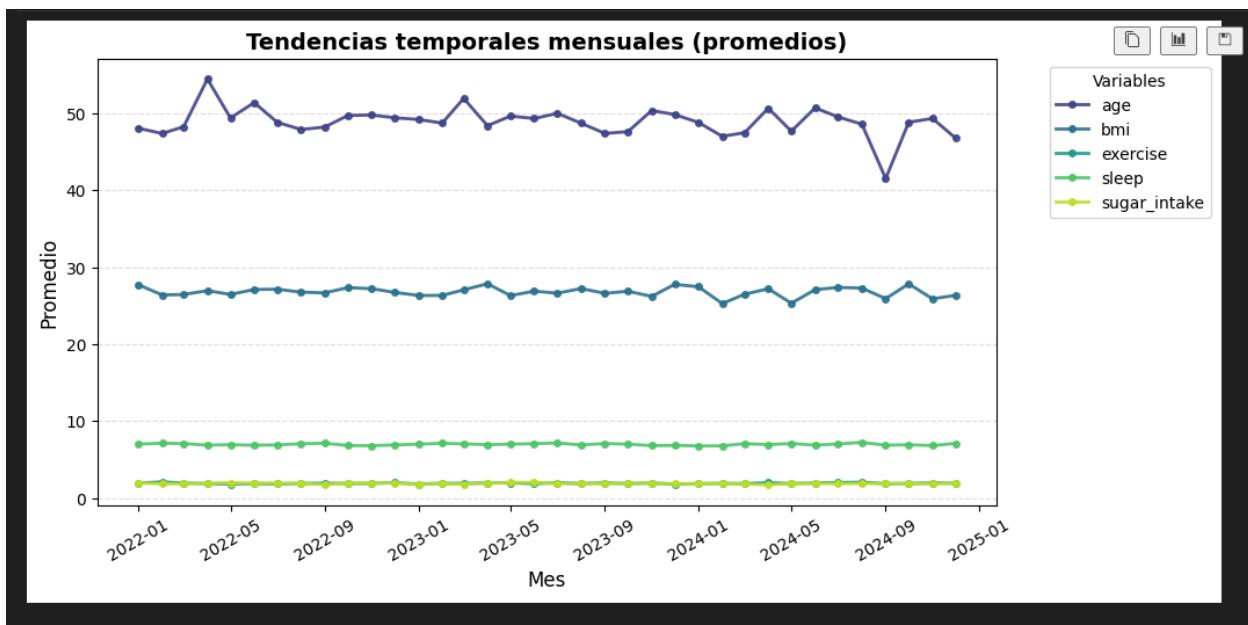
Interpretación: centrado en 6-8h, con grupo minoritario en déficit (<6h).

La distribución del **sueño** está centrada entre 6 y 8 horas, indicando hábitos de descanso relativamente adecuados. Sin embargo, existe una cola en valores bajos (3–5 horas) que representa posibles casos de privación de sueño.



Interpretación: mayoría baja-media, pocos casos altos relevantes para riesgo metabólico.

La ingesta de azúcar se concentra en niveles 1 y 2 (baja y media). Nivel 3 (alta) aparece con poca frecuencia. Esto demuestra que la mayoría de la población mantiene una **ingesta moderada**, aunque el pequeño grupo con consumo alto puede ser relevante para análisis de salud metabólica.



El análisis de tendencias temporales mostró que los promedios mensuales de las variables estudiadas —edad, IMC, ejercicio, sueño e ingesta de azúcar— se mantuvieron estables entre 2022 y 2024, sin fluctuaciones relevantes. Esta ausencia de variación es coherente con el uso de fechas generadas de manera aleatoria para fines metodológicos.

Aun así, la revisión temporal aporta valor al proceso exploratorio: permite confirmar que no existen picos artificiales ni comportamientos irregulares, valida la homogeneidad del dataset enriquecido y contribuye a la calidad del análisis exploratorio.

Repositorio

https://github.com/JuanUrrego/EA_proyecto_integrado_V_20251-2

Conclusiones

El trabajo realizado permitió consolidar un conjunto de datos limpio, estructurado y enriquecido, adecuado para el análisis de estilos de vida y su relación con los riesgos de salud en población adulta de Medellín. A través de procesos rigurosos de depuración, normalización, categorización y generación de variables temporales, se logró transformar un dataset crudo en una fuente de información confiable y coherente. El análisis descriptivo y las visualizaciones desarrolladas aportaron una comprensión clara de los patrones presentes en la población, destacando tendencias relevantes en IMC, niveles de ejercicio, hábitos de sueño e ingesta de azúcar. Este resultado constituye un insumo analítico sólido que evidencia la calidad del tratamiento de los datos y la capacidad del proceso para revelar comportamientos significativos relacionados con la salud.

Referencias

Kaggle. (2025). Lifestyle and Health Risk Prediction Dataset. Kaggle.

<https://www.kaggle.com/datasets/zahranusrat/lifestyle-and-health-risk-prediction-dataset>

Purdue OWL. (n.d.). General Format – APA 7th Edition. Purdue Online Writing Lab.

https://owl.purdue.edu/owl/research_and_citation/apa_style/apa_formatting_and_style_guide/general_format.html

Python Software Foundation. (n.d.). Python 3.9.12 Documentation.

<https://www.python.org/>

Pandas Development Team. (n.d.). pandas: Python Data Analysis Library.

<https://pandas.pydata.org/>

GitHub - Change is constant. GitHub keeps you ahead. (s/f).